Fase 2. Comprensión de los datos

Diana Laura Hernández Almeida
Gonzalo Makenly Higuera Inzunza
José Alfredo López Torres
Juan Pablo De La Peña Gonzalez
Sarah Camila Guzmán Fierro

April 13, 2026

Identificación de las variables de estudio y su relevancia

Los datos incluyen 14 variables y 28,654 observaciones. El archivo de nomenclatura contiene la sintaxis y el significado de alguno de los terminos usados. Esto de manera resumida, por lo que es necesario un diccionario que relacione cada variable con su significado explícito.

Diccionario de datos

Las variables se clasifican en cuatro grupos: identificación (`sensor_periodo`, `datetime`); gases contaminantes (`CO2_ppm`, `TVOC_ppb`, `CO_ppm`, `SO2_ppm`, `O3_ppm`, `NO2_ppm`); material particulado (`PM2_5_ugm3` en $\mu g/m^3$ para partículas $< 2.5\,\mu m$, `PM10_ugm3` para $\leq 10\,\mu m$); y variables ambientales y operativas (`temp_C` en °C, `hum_pct` y `Bat_pct` en %). La variable de respuesta es `AQI`, índice de calidad del aire en escala 1–5.

Para el problema, la más relevante es el índice de Calidad del Aire (AQI), si asumimos esta como variable de respuesta. En principio los predictores más relevantes son los diferentes compuestos y la temperatura; a menos de que entre algunos de ellos exista una correlación, entonces se mantendrían aquellos compuestos escenciales no correlacionados. Para la fecha y el tiempo se contemplaría su uso dependiendo del tipo de modelo que se planteé. Con respecto al sensor y su periodo, se extraería el identificador del sensor de la variable, para basar el anális en uno de estos; sería necesario verificar si el periodo es relevante para el modelo. Un aspecto a destacar son las variables de porcentaje de humedad relativa del aire y porcentaje de nivel de batería del sensor, puesto que estas puedieran no parecer relevantes, en especial el nivel de batería; sin embargo si se identifica que el nivel de batería del sensor influye en la exactitud de las muestras, esto quiere decir que el error depende del timepo, entonces se podría velar por un modelo de Regresión con errores autorregresivos.

Consideren filtrar los datos por alguna ubicación específica y basen su análisis en esa ubicación

Tras revisar que los datos no contienen información faltante, no es posible decidirlo de esa forma. Es por eso que, debido al mayor número de observaciones con las que cuenta el Sensor D, esta será la ubicación a analizar. Aún así queda puerta abierta a decantarnos por otro sensor, si se trata de datos díficiles de tratar, sin embargo, antes será necesario vefiricarlo con el Análisis Exploratorio Inicial. Los datos del filtrados incluyen 14 variables y 13,758 observaciones.

Análisis exploratorio inicial

Distribución y comportamiento temporal

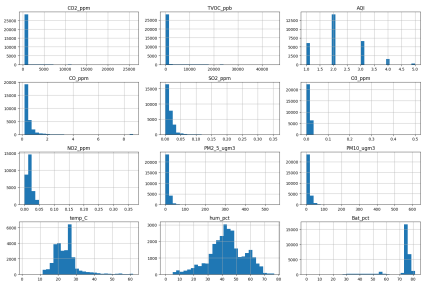

Figure 1: Distribución de las variables numéricas

La mayoría de variables presentan distribuciones sesgadas a la derecha, especialmente los gases contaminantes (CO_2, TVOC, CO) y las partículas (PM2.5, PM10), indicando episodios de alta concentración. Temperatura y humedad muestran distribuciones más estables, aproximadamente normales.

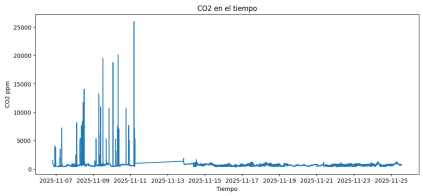

Figure 2: Serie temporal de CO_2

El CO_2 presenta picos abruptos en ciertos intervalos, posiblemente asociados a eventos atípicos o errores de medición, tras los cuales la señal se estabiliza.

Patrones por hora del día

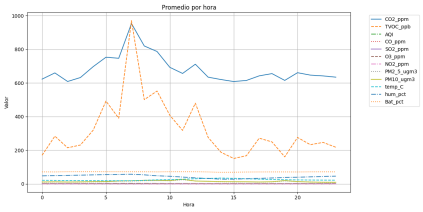

Figure 3: Promedio de variables por hora

CO_2 y TVOC incrementan en horas de mayor actividad humana. Temperatura y humedad siguen ciclos diarios esperados. Las partículas presentan menor variabilidad relativa pero tendencias similares.

Hallazgos principales

- Valores atípicos en múltiples variables y posible multicolinealidad entre contaminantes.
- Evidencia de patrones temporales diarios y correlación negativa entre temperatura y humedad.
- Alta correlación entre CO_2 y TVOC (≈ 0.96) y entre PM2.5 y PM10 (≈ 0.72), lo que sugiere aplicar selección de variables o reducción de dimensionalidad.

Discusión con estudiantes de Ingeniería Química

Coherencia física y química de los datos

Los valores basales de la mayoría de los contaminantes son coherentes con un ambiente urbano. Sin embargo, los picos de CO_2 superiores a 10,000 ppm en el periodo P1 superan lo esperado incluso en espacios cerrados, por lo que probablemente reflejan interferencias del sensor o proximidad a una fuente de combustión directa. La temperatura máxima de 61.6°C tampoco es representativa del ambiente atmosférico y sugiere exposición solar directa al sensor. La correlación alta entre CO_2, TVOC y CO es químicamente consistente, ya que los tres son productos típicos de combustión incompleta.

Selección de variables, transformaciones y feature engineering

Se propone conservar `CO_ppm`, `CO2_ppm`, `NO2_ppm`, `O3_ppm`, `PM2_5_ugm3` y `temp_C` como predictores principales, descartando TVOC por su alta redundancia con CO_2. Para reducir el efecto de valores extremos se sugiere aplicar transformación logarítmica a CO_2, TVOC, CO y las partículas. Como feature engineering, extraer la hora del día y el día de la semana desde la fecha podría ayudar a capturar patrones de tráfico y actividad humana.

Valores esperados y atípicos

Los valores atípicos más notables son CO_2 mayor a 5,000 ppm, TVOC mayor a 3,000 ppb, PM2.5 mayor a 200 $\mu g/m^3$ y registros con batería en 0%. Antes de eliminarlos se recomienda analizarlos en contexto temporal, ya que algunos podrían corresponder a eventos reales de contaminación. Los registros con batería en cero merecen atención especial pues podrían ser lecturas tomadas durante fallas del sensor.