

Fase 3. Preparación de los datos

Diana Laura Hernández Almeida
Gonzalo Makenly Higuera Inzunza
José Alfredo López Torres
Juan Pablo De La Peña Gonzalez
Sarah Camila Guzmán Fierro

May 3, 2026

1 Introducción

El objetivo es construir un conjunto de datos limpio, consistente y adecuado para modelación. Se detallará el proceso ETL (Extract, transform, load) durante el reporte, así mismo su justificación y validación en cuanto a conceptos químicos.

2 Proceso ETL

El proceso ETL se compone de tres etapas: Extracción, Transformación y Carga. Su objetivo es limpiar la información, manejar datos atípicos, imputar valores faltantes y estandarizar las variables para que sean adecuadas para el modelado. Antes de comenzar con el proceso ETL, se definen reglas basadas en el conocimiento previo. Se define el umbral de correlación en 0.9, se definen las variables TVOC_ppb y PM10_ugm3 para ser eliminadas por su alta correlación, se definen umbrales para cada variable basados en la literatura y finalmente se define el umbral de batería baja.

2.1 Extracción

El método de extracción carga los archivos `.xlsx`. Posteriormente separa la columna `sensor_periodo` en dos columnas independientes: `sensor` y `periodo`, y crea un DataFrame por cada sensor solicitado. Si el periodo es el mismo para todos los registros del sensor, se elimina esa columna. Finalmente ordena los datos cronológicamente usando `datetime`.

2.2 Transformación

La transformación se compone de tres etapas: limpieza, imputación y estandarización/normalización. Esta sigue un patrón de `Fit` y `Transform`, es decir, primero aprende los parámetros necesarios y posteriormente los aplica a los datos.

2.2.1 Limpieza

Este paso usa los métodos `__clean_fit` y `__clean_transform` para eliminar datos y decidir qué es un error de medición. Primero elimina las columnas altamente correlacionadas. Posteriormente se detectan valores atípicos siguiendo la siguiente lógica: Un dato se marca como valor atípico cuando hay discordancia entre el `AQI` y las concentraciones de contaminantes. Si el `AQI` es alto, pero no hay contaminante que lo justifique, se marca como sospechoso. Usando el criterio de la batería se eliminan los datos sospechosos: Si hay un dato sospechoso y la batería es baja, se clasifica como error de medición y se elimina el dato. Si hay un dato sospechoso y la batería es alta, se mantiene el dato.

2.2.2 Imputación

Este paso utiliza los métodos `__impute_fit` y `__impute_transform`. Después de la limpieza, se verifica que no queden datos faltantes generados por la misma. En caso de que existan, se imputa el valor usando interpolación lineal. Este método se elige porque es sencillo, rápido y adecuado para datos temporales.

2.2.3 Estandarización y Normalización

Este paso utiliza los métodos `__norm_std_fit` y `__norm_std_transform`. Para estandarizar y normalizar los datos, estos se separan en dos grupos: contaminantes y variables ambientales/batería. Para los contaminantes ambientales se utiliza la estandarización `Z-Score`, la cual resta la media y divide por la desviación estándar, y se normaliza para que esté entre 0 y 1. Para la temperatura, humedad y batería se utiliza la normalización Min-Max, la cual resta el valor mínimo y divide por el rango. De igual forma, se normaliza para que esté entre 0 y 1.

2.3 Load

La última etapa del proceso ETL es la carga, la cual crea una carpeta llamada `/Load/` si no existe, y exporta cada `DataFrame` de sensor procesado a un único archivo `.csv`.