

Fase 4. Modelación

Diana Laura Hernández Almeida
Gonzalo Makenly Higuera Inzunza
José Alfredo López Torres
Juan Pablo De La Peña Gonzalez
Sarah Camila Guzmán Fierro

May 25, 2026

1 Introducción

El objetivo de este entregable es probar y comparar distintos modelos, incluyendo los siguientes tres tipos: modelos de regresión, modelos de machine learning y modelos de deep learning.

2 Modelación

2.1 Modelos de regresión

En este apartado se utilizaron Regresión Lineal y Ridge como modelos base. Para Ridge, el mejor valor de α fue seleccionado mediante `RidgeCV` con validación cruzada de 5 pliegues sobre un rango logarítmico, obteniendo $\alpha = 1668.1005$. La evaluación se realizó con validación cruzada de 5 pliegues (`KFold`, `random_state=42`).

Table 1: Modelos de regresión

Model	R^2	σ_{R^2}	RMSE	σ_{RMSE}	MAE	σ_{MAE}
Linear Regression	0.4586	0.0562	0.6798	0.0365	0.5036	0.0045
Ridge ($\alpha = 1668.10$)	0.4466	0.0321	0.6878	0.0203	0.5226	0.0026

Ambos modelos obtuvieron un R^2 promedio de aproximadamente 0.45, explicando cerca del 45% de la varianza del AQI. Ridge presentó menor varianza entre pliegues ($\sigma_{R^2} = 0.032$ frente a 0.056), lo que lo hace más estable, aunque ninguno supera al otro de forma significativa. La verificación de supuestos reveló fallas en normalidad de residuos y homocedasticidad ($p = 0.000$ en ambos casos), y un estadístico Durbin-Watson de 0.44 y 0.37 respectivamente, indicando fuerte autocorrelación positiva. Estos resultados justifican la exploración de modelos con mayor capacidad expresiva.

2.2 Modelos de machine learning

En este apartado, se utilizaron los siguientes modelos con sus correspondientes resultados. Se optó por utilizar Support Vector Regression y XGBoost como regresor.

Table 2: Modelos de machine learning

Model	RMSE	MAE
Support vector regression	0.2679	0.1809
XGBoost regression	0.1894	0.0710

2.2.1 Modelos de deep learning

Para modelos de Deep Learning se seleccionaron Vanilla Recurrent Neural Network y Gated Recurrent Units (GRU). Dentro de los hiperparámetros iniciales, para ambos métodos se seleccionaron 64 capas ocultas, un dropout de probabilidad 0.2, 100 épocas, apilamiento de dos capas y una velocidad de aprendizaje de 1×10^{-3} . Tras computar ambos algoritmos, se obtuvieron los resultados de la tabla a continuación.

De ambos modelos, es fácil ver que el Vanilla RNN fue el sobresaliente en esta configuración inicial.

Table 3: Modelos de deep learning

Model	RMSE	MAE
Vanilla RNN	0.2459	0.1826
GRU	0.2792	0.2255

Table 4: GRU Hyperparameter Search Space

Hyperparameter	Values
Hidden size	32, 64, 128
Num layers	1, 2
Dropout	0.0, 0.2, 0.3
Learning rate	1×10^{-3} , 5×10^{-4}
Batch size	32, 64

2.2.2 Cross Validation con GRU para Selección de Hiperparámetros

Para realizar la validación cruzada, se generalizan los scripts iniciales. Los hiperparámetros a optimizar serían las capas ocultas, el apilamiento de capas, la probabilidad de dropout, el paso de aprendizaje y el tamaño de los grupos.

De forma estándar se hacen cinco pliegues y 50 épocas para reducir el tiempo de cómputo. Con un tiempo estimado de 50 minutos para computar las 72 variantes, los mejores resultados se enlistan a continuación:

Table 5: Top GRU Configurations by Cross-Validation RMSE

Hidden size	Num layers	Dropout	LR	Batch size	Mean RMSE	Std RMSE
128	2	0.2	1×10^{-3}	32	0.1962	0.0108
128	2	0.0	1×10^{-3}	32	0.2008	0.0086
128	2	0.3	1×10^{-3}	32	0.2171	0.0304

2.3 Modelo Final

Tras evaluar los tres enfoques de modelación, el modelo seleccionado como definitivo es **XGBoost** con hiperparámetros optimizados mediante **RandomizedSearchCV** con validación cruzada de 5 pliegues. Los mejores hiperparámetros encontrados fueron **n_estimators=100**, **max_depth=None** y **learning_rate=0.1**.

La selección de XGBoost sobre el GRU con validación cruzada se justifica por las siguientes razones:

- **MAE inferior:** XGBoost obtuvo un MAE de 0.0690 frente a 0.0713 del GRU optimizado, lo que indica un menor error absoluto promedio en la predicción del AQI.
- **Resultados comparables en RMSE:** La diferencia en RMSE entre ambos modelos es marginal (0.1901 vs 0.1827), sin representar una ventaja práctica significativa para el GRU.
- **Eficiencia computacional:** XGBoost requiere una fracción del tiempo de entrenamiento en comparación con el GRU, que demanda múltiples épocas y un proceso de validación cruzada de aproximadamente 50 minutos.
- **Interpretabilidad:** XGBoost permite analizar la importancia de las variables (*feature importance*), lo cual es valioso para comprender qué sensores contribuyen más a la predicción del AQI.

Table 6: Comparación final: GRU (CV-tuned) vs XGBoost (tuned)

Model	RMSE	MAE
GRU (CV-tuned)	0.1827	0.0713
XGBoost (tuned)	0.1901	0.0690

En conclusión, XGBoost representa el mejor balance entre rendimiento predictivo, costo computacional e interpretabilidad para el problema de predicción del AQI a partir de datos de sensores ambientales.